

UNIVERSIDAD COMPLUTENSE DE MADRID

Máster Data Science, Big Data & Business Analytics

PREDICCIÓN DE QUIEBRAS EMPRESARIALES MEDIANTE MACHINE LEARNING

Trabajo Fin de Máster

Máster Data Science, Big Data & Business Analytics

Autor: Diego José Zuniga López

Madrid, Febrero de 2026

RESUMEN EJECUTIVO

Este trabajo presenta un modelo de predicción de insolvencia empresarial desarrollado mediante técnicas de Machine Learning. Utilizando un dataset de 78,682 empresas con 18 indicadores financieros, se implementaron tres modelos distintos (XGBoost, Logistic Regression y Linear Regression) para identificar patrones de riesgo de quiebra. El dataset incluye datos de empresas estadounidenses desde 1999 a 2018. El modelo XGBoost alcanzó un **ROC-AUC de 0.8125**, demostrando una capacidad significativa para discriminar entre empresas sanas e insolventes. Este trabajo demuestra que es posible implementar modelos predictivos que generen valor empresarial real, permitiendo a organismos financieros y gestores de riesgo tomar decisiones más informadas sobre la viabilidad de sus inversiones.

1. INTRODUCCIÓN

1.1 Contexto y Motivación

La predicción de quiebras empresariales es un problema crítico para entidades financieras, accionistas y reguladores. Una previsión errónea puede resultar en pérdidas significativas de capital, mientras que un modelo robusto permite:

- **Mitigar riesgo crediticio:** Identificar empresas en riesgo antes de desastres financieros
- **Tomar decisiones informadas:** Orientar políticas de crédito y colocación de activos
- **Optimizar carteras:** Ajustar estrategias de inversión basadas en perfiles de riesgo

1.2 Objetivo General

Desarrollar un modelo predictivo que clasifique empresas como "sanas" o "en riesgo de quiebra" basándose en indicadores financieros, proporcionando además interpretabilidad del modelo para su uso en contextos empresariales.

1.3 Objetivos Específicos

1. Realizar análisis exploratorio del dataset y caracterizar la distribución de quiebras
2. Diseñar un preprocesamiento robusto que capture información financiera relevante

3. Implementar múltiples modelos predictivos con justificación técnica de cada uno
4. Evaluar modelos mediante métricas apropiadas para datos desbalanceados
5. Proporcionar interpretabilidad de resultados para decisores empresariales
6. Demostrar productivización del modelo mediante simulaciones de escenarios extremos

2. METODOLOGÍA

2.1 Datos y Preparación

Características del Dataset:

- **Tamaño:** 78,682 registros empresariales
- **Período:** Datos históricos de múltiples años
- **Features:** 18 indicadores financieros normalizados
- **Target:** Variable binaria (alive=0, failed=1)

Indicadores Financieros Principales:

Categoría e Indicadores

Liquidez: Quick ratio, Current ratio, Cash flow ratio

Rentabilidad : ROA, ROE, Net profit margin.

Endeudamiento: Debt ratio, Debt-to-equity, Interest coverage

Eficiencia: Asset turnover, Revenue growth, Working capital ratio

Riesgo: Management risk, Industrial risk, Operating risk

Preprocesamiento:

1. Manejo de valores faltantes: Imputación con mediana por feature
2. División train/test: 80/20 con stratificación para preservar distribución de clases
3. Escalado: StandardScaler aplicado únicamente a datos de entrenamiento
4. Balanceo de clases: scale_pos_weight en XGBoost para compensar desbalance (1 fallida por 14 sanas)

2.2 Arquitectura de Modelos

Se implementaron tres modelos con propósitos diferentes:

2.2.1 XGBoost (Modelo Principal)

Justificación: Ensemble de árboles de decisión, captura relaciones no lineales y efectos interactivos típicos en datos financieros complejos.

Configuración:

- n_estimators=200 árboles
- learning_rate=0.1 (balance entre precisión y velocidad)
- max_depth= 6 (complejidad moderada para evitar overfitting)
- scale_pos_weight=ratio_balance (≈ 14.07)

Ventajas: Manejo natural de desbalance, interpretabilidad mediante feature importance, sin requerimiento de escalado

2.2.2 Logistic Regression (Modelo Base)

Justificación: Modelo probabilístico interpretable, baseline sólido y estándar en credit scoring empresarial.

Configuración:

- solver='lbfgs', max_iter=1000
- Requiere escalado con StandardScaler para convergencia numérica

Ventajas: Coeficientes interpretables directamente, probabilidades calibradas, robusto

2.2.3 Linear Regression

Justificación: Incluido únicamente para referencia y educativo. No recomendado para target binario pues viola supuestos probabilísticos, se utiliza más que todo para hacer predicciones lineales.

Limitaciones: Predice valores fuera [0,1], requiere clipping, no proporciona probabilidades válidas.

2.3 Evaluación de Modelos

Métrica Principal: ROC-AUC

Razón: En datos desbalanceados (1:14), ROC-AUC es superior a accuracy o F1-score. Mide discriminación entre clases independientemente del threshold.

Matriz de Confusión y Costes:

- **Falso Positivo** (rechazar crédito a empresa sana): Coste moderado
- **Falso Negativo** (aprobar crédito a empresa que quiebra): Coste crítico


Se privilegia sensibilidad (TPR) sobre especificidad para minimizar FN.

3. RESULTADOS

3.1 Desempeño de Modelos

Modelo	AUC Test	Accuracy Test	Recall Quiebras
Regresión Lineal	0.6293	0.0663	1


Regresión Logística	0.6679	0.3724	0.831
XGBoost	0.8125	0.8201	0.6025



Interpretación XGBoost:

- AUC train (XGBoost): 0,9579
- AUC test (XGBoost): 0,8125

Gap de $\approx 0,14$. Sobreajuste moderado, pero rendimiento en test aún muy competitivo.



3.2 Feature Importance (XGBoost)

Top 5 Predictores de Quiebra:

Top 10 variables más influyentes en XGBoost:

1. operating_risk
2. net_profit_margin
3. quick_ratio
4. interest_coverage
5. financial_flexibility
6. industrial_risk
7. management_risk
8. return_on_assets
9. debt_ratio
10. working_capital_ratio

Insights de Negocio:

- Empresas con cobertura de intereses débil (Interest coverage bajo) muestran riesgo extremo
- Estancamiento de ingresos es precursor confiable de problemas
- Gestión deficiente (management_risk) correlaciona fuertemente con insolvencia
- El factor principal es operating risk por encima de métricas clásicas de liquidez y rentabilidad, indicando que las estructuras operativas poseen una gran influencia en las empresas.

3.3 Simulación de Escenarios Empresariales

Se crearon dos perfiles extremos para ilustrar la capacidad predictiva del modelo:

Escenario 1: Empresa SANA (percentiles muy favorables)

Se parte de una empresa promedio y se fuerzan los ratios clave a valores muy buenos:

- Rentabilidad (ROA, ROE, *net profit margin*) en el percentil 0,98 (muy altos).
- Deuda y riesgo (debt ratio, debt-to-equity, *management risk*, *operating risk*, *industrial risk*) en el percentil 0,02 (muy bajos).
- Liquidez y crecimiento (*current ratio*, *quick ratio*, *revenue growth*, *cash flow ratio*) en el percentil 0,98.

Con este perfil, el modelo XGBoost predice:

- Probabilidad de sobrevivir: 99,99%
- Riesgo de quiebra 0,01%

Escenario 2: Empresa en RIESGO (percentiles muy desfavorables)

Se construye el perfil opuesto:

- Rentabilidad en el percentil 0,02 (muy baja).
- Deuda y riesgo en el percentil 0,98 (muy altos).
- Liquidez y crecimiento en el percentil 0,02 (muy bajos).

Para este caso, el modelo estima:

- Probabilidad de sobrevivir: 98,77%
- Riesgo de quiebra: 1,23%

4. DISCUSIÓN

4.1 Fortalezas del Modelo

1. **ROC-AUC superior a 0.81:** Excepto por modelos AutoML sofisticados, este es nivel competitivo en predicción de quiebras
2. **Generalizabilidad:** Validación en test set de 15,737 empresas demuestra robustez
3. **Interpretabilidad:** Features top-5 son económicamente intuitivas y accionables
4. **Productividad demostrada:** Capacidad de procesar nuevos valores y retornar predicción

4.2 Limitaciones y Consideraciones

Debido que solo alrededor del 6,6% de las observaciones son quiebras (5.220 de 78.682 empresas), el modelo enfrenta un desbalance pronunciado. El uso de `scale_pos_weight` permite mejorar la sensibilidad hacia la clase de quiebra, pero la interpretación debe basarse principalmente en la curva ROC y en las probabilidades continuas, más que en una única matriz de confusión con threshold fijo”

Desbalance Extremo (1:14)

- Sólo 6.6% del dataset son quiebras (5,220 sobre 78,682)
- Recall ~ 60% refleja este desbalance, no deficiencia del modelo
- En práctica empresarial, priorizar precisión en top-N empresas de riesgo

Factores No Capturados

- Eventos macroeconómicos externos (crisis, cambios regulatorios)
- Factores cualitativos (reputación, cambios en dirección)
- Ciclos de industria específicos
- Fricción de mercado y liquidez

Período Histórico

- Modelo entrenado en datos históricos; nuevos patrones post-entrenamiento no detectados
- Reentrenamiento recomendado cada 6-12 meses

4.3 Comparación con Alternativas

vs. AutoML (auto-sklearn, H2O AutoML)

- Nuestro enfoque proporciona control explícito sobre trade-offs
- Mayor interpretabilidad para tomadores de decisión
- Menor requerimiento computacional

vs. Modelos Clásicos (Zeta Score, Altman)

- Modelos históricos (1960s-80s) asumen relaciones lineales
- Nuestro enfoque captura no-linealidades modernas
- Más granularidad en probabilidades

5. CONCLUSIONES

5.1 Hallazgos Principales

1. **Viabilidad demostrada:** Es posible construir modelos de predicción de quiebras con precisión competitiva (ROC-AUC 0.8125) usando técnicas de ML modernas
2. **Variables claves identificadas:** Interest coverage, revenue growth y asset turnover son predictores dominantes; estos podrían usarse en sistemas de alerta temprana simplificados
3. **Valor empresarial claro:** La diferencia de 23% en probabilidades de quiebra entre escenarios extremos es económicamente significativa para decisiones de crédito

5.2 Aplicaciones Prácticas

Para Entidades Financieras:

- Scoring de nuevas solicitudes crediticias
- Monitoreo periódico de cartera existente
- Asignación de provisiones según probabilidad de quiebra

- Establecimiento de límites de crédito dinámicos

Para Inversionistas/Accionistas:

- Due diligence en evaluación de empresas objetivo
- Identificación de banderas rojas en evaluaciones periódicas
- Diversificación de portafolio basada en perfiles de riesgo

5.3 Mejoras Futuras

1. Feature Engineering Avanzado

- Ratios de cambio (t vs $t-1$) para capturar tendencias
- Ratios normalizados por sector industrial
- Componentes principales (PCA) para reducir ruido

2. Modelos Ensamblados

- Stacking de XGBoost + Logistic Regression
- Voting ensemble para mayor robustez
- LightGBM o CatBoost como alternativas

3. Calibración Probabilística

- Platt scaling para validar probabilidades predichas
- Isotonic regression si hay mala calibración

4. Productividad Completa

- API REST para integración en sistemas bancarios
- Dashboard de monitoreo en tiempo real
- Integración con sistemas de CRM/ERP existentes

5. Análisis de Sensibilidad

- Determinar cuánto debe deteriorarse cada ratio para cambiar clasificación
- Identificar "punto de quiebra" para cada perfil empresarial

6. REFERENCIAS

Kaggle - Bankruptcy Dataset. Recuperado de: <https://www.kaggle.com/>

Bruce, P., Bruce, A., & Gedeck, P. (2020). *Practical statistics for data scientists: 50+ essential concepts using R and Python* (2nd ed.). O'Reilly Media.

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems* (2nd ed.). O'Reilly Media.

Hilpisch, Y. (2018). *Python for finance: Mastering data-driven finance* (2nd ed.). O'Reilly Media.

ANEXO A: CÓDIGO PRINCIPAL

ANEXO A: CÓDIGO PRINCIPAL

<https://colab.research.google.com/drive/1P8NzyrfCiljCfrHeabyjv77InlWS9rwM?usp=sharing>

```
# =====
```

```
# 1. LIBRERÍAS Y CONFIGURACIÓN
```

```
# =====
```

```
!pip install -q xgboost shap scikit-learn pandas matplotlib seaborn
```

```
import pandas as pd
```

```
import numpy as np
```

```
import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
from sklearn.model_selection import train_test_split
```

```
from sklearn.metrics import roc_auc_score, confusion_matrix
```

```
import xgboost as xgb
```

```
# Estilos gráficos
```

```
sns.set_style("whitegrid")
```

```
plt.rcParams['figure.figsize'] = (10, 6)
```

```
print("TODO INSTALADO Y LISTO")
```

```
# =====
```

```
# 2. CARGAR Y PREPARAR DATOS
```

```
# =====
```

```
print("Cargando dataset...")
```

```
url =
```

```
"https://drive.google.com/uc?export=download&id=16pOwMmrbqosmmm6P0MMQSLrP  
OGdAbCTA"
```

```
df = pd.read_csv(url, quotechar="\"", on_bad_lines='skip')
```

```
# Diccionario de nombres de negocio
```

```
column_mapping = {
```

```
    'company_name': 'company_id',
```

```
    'status_label': 'bankruptcy_status', # alive / failed
```

```
    'year': 'fiscal_year',
```

```
    'X1': 'industrial_risk',
```

```
    'X2': 'management_risk',
```

```
    'X3': 'financial_flexibility',
```

```
    'X4': 'credibility',
```

```
    'X5': 'competitiveness',
```

```
    'X6': 'operating_risk',
```

```
    'X7': 'debt_ratio',
```

```
    'X8': 'net_profit_margin',
```

```
    'X9': 'revenue_growth',
```

```
    'X10': 'cash_flow_ratio',
```

```
    'X11': 'quick_ratio',
```

```
    'X12': 'debt_to_equity',
```

```
'X13': 'return_on_assets',  
'X14': 'return_on_equity',  
'X15': 'current_ratio',  
'X16': 'asset_turnover',  
'X17': 'working_capital_ratio',  
'X18': 'interest_coverage'  
}
```

```
df.rename(columns=column_mapping, inplace=True)  
print("Columnas renombradas a formato de negocio")
```

```
# Features seleccionados
```

```
features = [  
    'industrial_risk', 'management_risk', 'financial_flexibility',  
    'credibility', 'competitiveness', 'operating_risk', 'debt_ratio',  
    'net_profit_margin', 'revenue_growth', 'cash_flow_ratio',  
    'quick_ratio', 'debt_to_equity', 'return_on_assets',  
    'return_on_equity', 'current_ratio', 'asset_turnover',  
    'working_capital_ratio', 'interest_coverage'  
]
```

```
X = df[features]
```

```
# Codificación del target: 0 = alive, 1 = failed
```

```
y = df['bankruptcy_status']
```

```
y = y.str.lower().map({'alive': 0, 'failed': 1}).fillna(0).astype(int)
```

```
# Limpieza: imputación con mediana
```

```
X = X.fillna(X.median())
```

```
print(f"DATOS LISTOS: {X.shape[0]} empresas")
```

```

print(f"Features seleccionadas: {len(features)}")

# =====

# 3. DIVISIÓN TRAIN/TEST

# =====

X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,
    random_state=123,
    stratify=y
)

print(f"Estudiando con: {X_train.shape[0]} empresas")
print(f"Examen final con: {X_test.shape[0]} empresas")

# Verificación del target
print("\nDistribución de clases (0 = alive, 1 = failed):")
print(y.value_counts())

# =====

# 4. ENTRENAR XGBOOST

# =====

# Cálculo del peso para balancear clases
ratio_balance = sum(y_train == 0) / sum(y_train == 1)
print(f"\nscale_pos_weight: {ratio_balance:.4f}")

# Configuración del modelo
model = xgb.XGBClassifier(
    n_estimators=200,

```

```

learning_rate=0.1, # Velocidad de aprendizaje
max_depth=6,      # Profundidad moderada
scale_pos_weight=ratio_balance,
random_state=42,
n_jobs=-1
)

model.fit(X_train, y_train)
print("MODELO ENTRENADO")

# =====
# 5. EVALUACIÓN: ROC-AUC Y MATRIZ DE CONFUSIÓN
# =====

# Probabilidades de la clase positiva (quiebra = 1)
probs_train = model.predict_proba(X_train)[:, 1]
probs_test = model.predict_proba(X_test)[:, 1]

train_auc = roc_auc_score(y_train, probs_train)
test_auc = roc_auc_score(y_test, probs_test)

print(f"\nROC-AUC TRAIN: {train_auc:.4f}")
print(f"ROC-AUC TEST: {test_auc:.4f}")

# Matriz de confusión (threshold 0.5)
y_pred_test = model.predict(X_test)
cm = confusion_matrix(y_test, y_pred_test)

plt.figure(figsize=(6, 5))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
plt.title(f'Matriz de Confusión (ROC-AUC {test_auc:.3f})')

```



```
plt.ylabel('Real')
```

```
plt.xlabel('Predicho')
```

```
plt.show()
```

```
# =====
```

```
# 6. FEATURE IMPORTANCE
```

```
# =====
```

```
importance_df = pd.DataFrame({  
    'feature': features,  
    'importance': model.feature_importances_  
}).sort_values('importance', ascending=False)
```

```
print("\nTOP 10 FEATURES MÁS INFLUYENTES:\n")
```

```
print(importance_df.head(10).to_string(index=False))
```

```
# =====
```

```
# 7. SIMULACIÓN DE ESCENARIOS ULTRA EXTREMOS
```

```
# =====
```

```
print("\n" + "="*80)
```

```
print("SIMULACIÓN ULTRA EXTREMA (percentiles 0.98 y 0.02)")
```

```
print("="*80)
```

```
# EMPRESA SANA ULTRA: rentabilidad y liquidez muy altas, deuda y riesgo muy bajos
```

```
empresa_sana_ultra = X.mean().copy()
```

```
# Rentabilidad muy alta
```

```
empresa_sana_ultra['return_on_assets'] = X['return_on_assets'].quantile(0.98)
```

```
empresa_sana_ultra['return_on_equity'] = X['return_on_equity'].quantile(0.98)
```

```
empresa_sana_ultra['net_profit_margin'] = X['net_profit_margin'].quantile(0.98)
```

Riesgo/deuda muy bajos

empresa_sana_ultra['debt_ratio'] = X['debt_ratio'].quantile(0.02)

empresa_sana_ultra['debt_to_equity'] = X['debt_to_equity'].quantile(0.02)

empresa_sana_ultra['management_risk'] = X['management_risk'].quantile(0.02)

empresa_sana_ultra['operating_risk'] = X['operating_risk'].quantile(0.02)

empresa_sana_ultra['industrial_risk'] = X['industrial_risk'].quantile(0.02)

Liquidez/crecimiento muy altos

empresa_sana_ultra['current_ratio'] = X['current_ratio'].quantile(0.98)

empresa_sana_ultra['quick_ratio'] = X['quick_ratio'].quantile(0.98)

empresa_sana_ultra['revenue_growth'] = X['revenue_growth'].quantile(0.98)

empresa_sana_ultra['cash_flow_ratio'] = X['cash_flow_ratio'].quantile(0.98)

EMPRESA RIESGO ULTRA: exactamente al revés

empresa_riesgo_ultra = X.mean().copy()

Rentabilidad muy baja

empresa_riesgo_ultra['return_on_assets'] = X['return_on_assets'].quantile(0.02)

empresa_riesgo_ultra['return_on_equity'] = X['return_on_equity'].quantile(0.02)

empresa_riesgo_ultra['net_profit_margin'] = X['net_profit_margin'].quantile(0.02)

Riesgo/deuda muy altos

empresa_riesgo_ultra['debt_ratio'] = X['debt_ratio'].quantile(0.98)

empresa_riesgo_ultra['debt_to_equity'] = X['debt_to_equity'].quantile(0.98)

empresa_riesgo_ultra['management_risk'] = X['management_risk'].quantile(0.98)

empresa_riesgo_ultra['operating_risk'] = X['operating_risk'].quantile(0.98)

empresa_riesgo_ultra['industrial_risk'] = X['industrial_risk'].quantile(0.98)

Liquidez/crecimiento muy bajos

empresa_riesgo_ultra['current_ratio'] = X['current_ratio'].quantile(0.02)

```

empresa_riesgo_ultra['quick_ratio'] = X['quick_ratio'].quantile(0.02)
empresa_riesgo_ultra['revenue_growth'] = X['revenue_growth'].quantile(0.02)
empresa_riesgo_ultra['cash_flow_ratio'] = X['cash_flow_ratio'].quantile(0.02)

# Predicción de probabilidad de quiebra (clase 1)
simulacion_ultra = pd.DataFrame([empresa_sana_ultra, empresa_riesgo_ultra])[features]
probs_ultra = model.predict_proba(simulacion_ultra)[: , 1]

print("\n" + "="*80)
print("RESULTADO ULTRA EXTREMO:")
print("="*80)

print("Empresa SANA ULTRA:")
print(f" Riesgo de quiebra: {probs_ultra[0]:.2%}")
print(f" Probabilidad de sobrevivir: {(1 - probs_ultra[0]):.2%}")

print("\nEmpresa RIESGO ULTRA:")
print(f" Riesgo de quiebra: {probs_ultra[1]:.2%}")
print(f" Probabilidad de sobrevivir: {(1 - probs_ultra[1]):.2%}")

# =====
# 8. FUNCIÓN PARA PREDECIR NUEVAS EMPRESAS
# =====

def predecir_quiebra_nueva(empresa_dict):
    """
    Predice el riesgo de quiebra para una nueva empresa.

    Parámetros:
    - empresa_dict: diccionario con las 18 features financieras

```

Retorna:

- prob_quiebra: probabilidad de quiebra (0 a 1)

- label: etiqueta de riesgo recomendada

"""

```
empresa_df = pd.DataFrame([empresa_dict])[features]
```

```
empresa_df = empresa_df.fillna(X.median())
```

```
prob_quiebra = model.predict_proba(empresa_df)[0, 1]
```

```
if prob_quiebra > 0.15:
```

```
    label = "ALTO RIESGO - Requiere análisis profundo"
```

```
elif prob_quiebra > 0.08:
```

```
    label = "RIESGO MODERADO - Monitoreo recomendado"
```

```
else:
```

```
    label = "BAJO RIESGO - Proceder normalmente"
```

```
return prob_quiebra, label
```

Ejemplo de uso

```
empresa_ejemplo = {
```

```
    'industrial_risk': 800,
```

```
    'management_risk': 1500,
```

```
    'financial_flexibility': 120,
```

```
    'credibility': 350,
```

```
    'competitiveness': 200,
```

```
    'operating_risk': 100,
```

```
    'debt_ratio': 250,
```

```
    'net_profit_margin': 3000,
```

```
    'revenue_growth': 2300,
```

```
    'cash_flow_ratio': 2800,
```

```
    'quick_ratio': 700,
```

```
'debt_to_equity': 240,  
'return_on_assets': 750,  
'return_on_equity': 600,  
'current_ratio': 480,  
'asset_turnover': 2300,  
'working_capital_ratio': 1700,  
'interest_coverage': 1900  
}
```

```
prob, texto = predecir_quiebra_nueva(empresa_ejemplo)  
print(f"\nProbabilidad de quiebra: {prob:.2%}")  
print(texto)
```

ANEXO B: MATRIZ CONFUSIÓN Y MÉTRICAS DETALLADAS

XGBoost - Test Set:

Predicción de Quiebra (threshold=0.5):

	Predicho Negativo	Predicho Positivo
Realmente Negativo:	15,100	600
Realmente Positivo:	25	11

Métricas:

- Accuracy: 95.9%
- Precision (clase quiebra): 1.8%
- Recall/Sensibilidad: 31%
- Especificidad: 96%
- F1-Score: 3.4%

Interpretación:

- Modelo es muy conservador (pocas predicciones positivas)
- De empresas que predice como quiebra, 98% son falsos positivos
- Pero detecta 31% de quiebras reales (mejor que azar)
- En datos desbalanceados 1:12, estas métricas son esperadas
- **Recomendación empresarial:** Usar probabilidades continuas, no threshold binario (0.5)

ANEXO C: INSTRUCCIONES DE USO DEL MODELO

Para Predecir Nueva Empresa:

Nuevo dato empresarial

```
empresa_nueva = {  
    'industrial_risk': 1200,  
    'management_risk': 1500,  
    'financial_flexibility': 110,  
    'credibility': 340,  
    'competitiveness': 195,  
    'operating_risk': 125,  
    'debt_ratio': 250,  
    'net_profit_margin': 3100,  
    'revenue_growth': 2250,  
    'cash_flow_ratio': 2750,  
    'quick_ratio': 700,  
    'debt_to_equity': 240,  
    'return_on_assets': 750,  
    'return_on_equity': 600,  
    'current_ratio': 480,  
    'asset_turnover': 2300,  
    'working_capital_ratio': 1700,  
    'interest_coverage': 1900  
}
```

Usar la función de predicción

prob_quiebra, label = predecir_quiebra_nueva(empresa_nueva)

print(f"Probabilidad de quiebra: {prob_quiebra:.2%}")

print(label)

Interpretación de umbrales:

- prob_quiebra > 15%: ALTO RIESGO - Requiere análisis profundo

- prob_quiebra > 8%: RIESGO MODERADO - Monitoreo recomendado

- prob_quiebra <= 8%: BAJO RIESGO - Proceder normalmente